

Câu 1:

a) Nêu 3 đặc trưng chính của Big Data (3V) và giải thích. (0.5 điểm)

Ba đặc trưng chính của Big Data là 3V:

Volume (Khối lượng): Dữ liệu có khối lượng rất lớn, thường tính bằng terabyte (TB), petabyte (PB) hoặc hơn. Ví dụ: Dữ liệu người dùng trên Facebook, video YouTube, hay log hệ thống.

Velocity (Tốc độ): Dữ liệu được sinh ra và cập nhật liên tục với tốc độ rất cao. Ví dụ: Dòng tweet, giao dịch ngân hàng, cảm biến IoT.

Variety (Đa dạng): Dữ liệu có nhiều định dạng khác nhau: có cấu trúc (SQL), bán cấu trúc (JSON, XML) và phi cấu trúc (hình ảnh, âm thanh, video).

b) Ngoài 3V, các đặc trưng mở rộng khác của Big Data là gì (5V)? (0.5 điểm)

Các đặc trưng mở rộng thành 5V gồm:

Veracity (Độ tin cậy): Dữ liệu có thể không chính xác, không nhất quán hoặc thiếu độ tin cậy, cần được làm sạch và xác thực.

Value (Giá trị): Mục tiêu cuối cùng của Big Data là khai thác giá trị hữu ích từ dữ liệu để hỗ trợ ra quyết định, dự báo, hoặc tối ưu hoạt động.

c) Giải thích khái niệm ETL (Extract – Transform – Load) trong Big Data. (1.0 điểm)

ETL là quy trình xử lý dữ liệu trong hệ thống Big Data hoặc Data Warehouse, gồm 3 bước chính:

Extract (Trích xuất): Lấy dữ liệu từ nhiều nguồn khác nhau như CSDL, file log, API, cảm biến,...

Transform (Chuyển đổi): Làm sạch, chuẩn hóa, thay đổi định dạng, tổng hợp hoặc tính toán dữ liệu để phù hợp với mô hình lưu trữ hoặc phân tích.

Load (Nạp dữ liệu): Nạp dữ liệu đã xử lý vào hệ thống lưu trữ đích, như Data Warehouse, Data Lake, hoặc hệ thống phân tích như Hadoop/Spark.

d) Hệ sinh thái Hadoop gồm những thành phần chính nào? (1.0 điểm)

Hệ sinh thái Hadoop bao gồm nhiều thành phần, trong đó các thành phần chính là:

HDFS (Hadoop Distributed File System): Hệ thống lưu trữ dữ liệu phân tán.

YARN (Yet Another Resource Negotiator): Quản lý tài nguyên và lập lịch xử lý.

MapReduce: Mô hình xử lý dữ liệu song song, chia công việc thành Map và Reduce.

e) Vì sao Spark được xem là phát triển thế hệ mới của Hadoop? (1.0 điểm)

Apache Spark được xem là thế hệ mới của Hadoop vì:

Xử lý nhanh hơn nhiều lần: Spark lưu trữ dữ liệu trong bộ nhớ (in-memory) thay vì đọc/ghi liên tục xuống đĩa như MapReduce → tốc độ nhanh gấp 10–100 lần.

Hỗ trợ đa dạng mô hình xử lý: Không chỉ xử lý batch mà còn streaming, machine learning, graph processing, SQL, tất cả trong một framework duy nhất.

Dễ lập trình hơn: Hỗ trợ nhiều ngôn ngữ: Scala, Java, Python, R, và cung cấp API thân thiện hơn MapReduce.

Tích hợp linh hoạt: Có thể chạy độc lập hoặc kết hợp với Hadoop (trên HDFS/YARN).

Câu 2:

A trở B, C

B trở D

C trở A,B,D

D trở C

	Vòng lặp 1	Vòng lặp 2		
A	$1/1 + 1/3 = 4/3$	$1/1 + 2.5/3$		
B	$1/1 = 1$	$0.33/1$		
C	$1/2 + 1/1 + 1/1 = 5/2$	$1.33/2 + 1/1 + 0.33/1$		
D	$1/3$	$2.5/3$		

Câu 3:

a) Mục tiêu chính của K-Means (0.25 điểm)

Mục tiêu: chia n điểm dữ liệu thành K cụm sao cho tổng bình phương khoảng cách (intra-cluster variance) giữa các điểm và tâm (centroid) của cụm tương ứng là nhỏ nhất. Nói ngắn: gom những điểm gần nhau thành cùng một cụm.

b) Các bước chính của thuật toán K-Means (0.75 điểm)

- Chọn K (số cụm) và khởi tạo K centroid (ngẫu nhiên hoặc theo quy tắc).
- Gán mỗi điểm cho cụm có centroid gần nhất (thường theo khoảng cách Euclid).
- Cập nhật centroid của mỗi cụm bằng trung bình tọa độ các điểm thuộc cụm đó.
- Lặp lại bước 2 và 3 cho đến khi hội tụ (không thay đổi phân cụm hoặc centroid ổn định) hoặc đạt ngưỡng vòng lặp.
(Ghi chú: chuẩn hoá/chuẩn bị dữ liệu và chạy nhiều lần với khởi tạo khác nhau giúp tránh cực trị địa phương.)

c) Bài toán cụ thể — $K = 2$, các điểm:

A(1,1), B(1.5,2), C(3,4), D(5,7), E(3.5,5), F(4.5,5), G(3.5,4.5), H(4,6)

Thực hiện K-Means với **khởi tạo centroid ban đầu** chọn là:

- Centroid₁ = A = (1,1)
- Centroid₂ = D = (5,7)

Mô tả **các vòng lặp** chính

Vòng 1 — gán điểm theo centroid ban đầu

Khoảng cách so sánh cho từng điểm → phân cụm:

- Cụm 1 (centroid₁ = A): A, B, C
- Cụm 2 (centroid₂ = D): D, E, F, G, H

(Tại vòng 1, C có khoảng cách bằng nhau với 2 centroid; ta gán theo quy tắc $\leq \rightarrow$ về cụm 1.)

Cập nhật centroid sau vòng 1 (lấy trung bình tọa độ các điểm trong cụm):

- Centroid₁ = trung bình(A,B,C) = $(1+1.5+3)/3, (1+2+4)/3 = (1.8333, 2.3333)$
- Centroid₂ = trung bình(D,E,F,G,H) = $(5+3.5+4.5+3.5+4)/5, (7+5+5+4.5+6)/5 = (4.1, 5.5)$

Vòng 2 — gán lại theo centroid mới

Tính khoảng cách tới hai centroid mới rồi gán:

- Cụm 1: A(1,1), B(1.5,2)
- Cụm 2: C, D, E, F, G, H

(Ở vòng 2, điểm C chuyển sang cụm 2 vì nó gần centroid₂ hơn.)

Cập nhật centroid sau vòng 2:

- Centroid₁ = trung bình(A,B) = $(1+1.5)/2, (1+2)/2 = (1.25, 1.5)$
- Centroid₂ = trung bình(C,D,E,F,G,H) = trung bình các tọa độ $\rightarrow (3.9167, 5.25)$ (6 điểm)

Vòng 3 — kiểm tra gán lại

Gán lại theo centroid mới:

- Kết quả vẫn giữ nguyên: Cụm 1 = {A, B}, Cụm 2 = {C, D, E, F, G, H}

Centroid không đổi so với vòng 2 \rightarrow **hội tụ**.

Kết quả cuối cùng (K = 2)

- **Cụm 1 (Cluster 1):** A(1,1), B(1.5,2)
 - Centroid $\approx (1.25, 1.50)$
- **Cụm 2 (Cluster 2):** C(3,4), D(5,7), E(3.5,5), F(4.5,5), G(3.5,4.5), H(4,6)
 - Centroid $\approx (3.9167, 5.25)$

(Thuật toán hội tụ sau 2 lần cập nhật centroid — tức sau ~ 2 vòng gán/cập nhật.)